Αναγνώριση Προτύπων & Μηχανική Μάθηση

Ακαδημαϊκό Έτος 2025–2026

Εργασία Εξαμήνου

Ομάδα 22

Κωνσταντίνος Απόστολος Κοτσόπουλος
ΑΕΜ: 10969

Νικόλαος Στανωτάς
ΑΕΜ: 1730

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Θεσσαλονίκη, Ιανουάριος 2026

Πίνακας περιεχομένων

Εισαγωγή & Δομή Εργασίας 2
Στόχος της Εργασίας 2
Δομή Παρουσίασης 2
1. Μέρος Α - Εκτίμηση Παραμέτρων Γκαουσιανών Κατανομών 3
1.1 Εκτίμηση Παραμέτρων Γκαουσιανών Κατανομών 3
1.2 Θεωρητικό Υπόβαθρο - Maximum Likelihood Estimation 3
1.3 Εκτίμηση Παραμέτρων για Κάθε Κλάση 4
1.4 Οπτικοποίηση Δεδομένων σε Δισδιάστατο Χώρο 4
1.5 Εκτιμώμενοι Μέσοι Όροι και Πίνακες Συνδιακύμανσης 5
1.6 Τρισδιάστατη Απεικόνιση Πυκνοτήτων Πιθανότητας (MLE) 6
2. Μέρος Β - Εκτίμηση Πυκνότητας Πιθανότητας με Parzen Windows 7
2.1 Θεωρητικό Υπόβαθρο — Parzen Windows 7
2.2 Πυρήνες Parzen και Διαδικασία Εκτίμησης 7
2.3 Έλεγχος Υπόθεσης Κατανομής Δεδομένων 8
2.4 Επιλογή Πλάτους Παραθύρου (h) 9
2.5 Αποτελέσματα και Σύγκριση Πυρήνων 10
3. Μέρος Γ - Ταξινόμηση με K-Nearest Neighbors 11
3.1 Θεωρητικό Υπόβαθρο — K-Nearest Neighbors 11
3.2 Υπολογισμός Αποστάσεων και Επιλογή Γειτόνων 12
3.3 Πρόβλεψη Κλάσης και Υπολογισμός Πιθανοτήτων 12
3.4 Επιλογή Βέλτιστης Τιμής k 13
3.5 Όρια Απόφασης του KNN Ταξινομητή 14
4. Μέρος Δ - Πολυκλασική Ταξινόμηση και Τελικό Μοντέλο 15
4.1 Περιγραφή Δεδομένων και Προκλήσεις Προβλήματος 15
4.2 Προεπεξεργασία Δεδομένων 16
4.3 Μείωση Διάστασης με PCA 16
4.4 Αρχικά Μοντέλα Ταξινόμησης 17
4.5 Παρατηρήσεις από τα Αποτελέσματα 18
4.6 Ιεραρχική Προσέγγιση Ταξινόμησης 18
4.7 Μοντέλο για το Group A 19
4.8 Μοντέλο για το Group B 19
4.9 Τελικό Ιεραρχικό Μοντέλο και Αξιολόγηση 20
4.10 Παραγωγή Τελικών Προβλέψεων 20
4.11 Συμπεράσματα Μέρους Δ 21

Εισαγωγή & Δομή Εργασίας

Στόχος της Εργασίας

- Εφαρμογή τεχνικών Στατιστικής Μάθησης & Ταξινόμησης
- Συνδυασμός:
    - θεωρητικών μοντέλων πιθανοτήτων
    - αλγορίθμων μηχανικής μάθησης
- Όλη η εργασία υλοποιήθηκε σε Python

Δομή Παρουσίασης

- **Μέρος Α**
  Εκτίμηση παραμέτρων δισδιάστατων Γκαουσιανών κατανομών με MLE
- **Μέρος Β**
  Εκτίμηση πυκνότητας πιθανότητας με Parzen Windows & επιλογή βέλτιστου πλάτος παραθύρου (h)
- **Μέρος Γ**
  Δυαδική ταξινόμηση με K-Nearest Neighbors και επιλογή παραμέτρου k
- **Μέρος Δ**
  Ταξινόμηση 5 κλάσεων και κατασκευή τελικού μοντέλου

1. Μέρος Α - Εκτίμηση Παραμέτρων Γκαουσιανών Κατανομών

1.1 Εκτίμηση Παραμέτρων Γκαουσιανών Κατανομών

Δεδομένα:

- Δίνεται το αρχείο dataset1.csv που περιέχει 300 δισδιάστατα δείγματα
- Κάθε δείγμα αποτελείται από δύο χαρακτηριστικά (x_1, x_2) και μία ετικέτα κλάσης
- Οι ετικέτες κλάσης ανήκουν στο σύνολο {0, 1, 2}

Υπόθεση Μοντέλου:

- Τα δεδομένα κάθε κλάσης ακολουθούν δισδιάστατη κανονική κατανομή
- Κάθε κλάση μοντελοποιείται ανεξάρτητα

Στόχος:

- Εκτίμηση του μέσου διανύσματος μ και του πίνακα συνδιακύμανσης Σ για κάθε κλάση
- Σχεδίαση των τριών πυκνοτήτων πιθανότητας στο ίδιο τρισδιάστατο γράφημα

1.2 Θεωρητικό Υπόβαθρο - Maximum Likelihood Estimation

- Υποθέτουμε ότι τα δεδομένα κάθε κλάσης ακολουθούν δισδιάστατη κανονική κατανομή

$$\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

- Η μέθοδος Maximum Likelihood Estimation (MLE) επιλέγει τις παραμέτρους που μεγιστοποιούν την πιθανότητα εμφάνισης των παρατηρούμενων δεδομένων
- Ο εκτιμητής του μέσου διανύσματος δίνεται από:

$$\widehat{\boldsymbol{\mu}} = \frac{1}{N}\sum_{i=1}^{N} \boldsymbol{x}_i$$

- Ο εκτιμητής του πίνακα συνδιακύμανσης δίνεται από:

$$\widehat{\boldsymbol{\Sigma}} = \frac{1}{N}\sum_{i=1}^{N} (\boldsymbol{x}_i - \widehat{\boldsymbol{\mu}})(\boldsymbol{x}_i - \widehat{\boldsymbol{\mu}})^T$$

- Οι παραπάνω εκτιμητές μεγιστοποιούν τη συνάρτηση πιθανοφάνειας υπό την υπόθεση κανονικής κατανομής

1.3 Εκτίμηση Παραμέτρων για Κάθε Κλάση

- Τα δεδομένα διαχωρίζονται σε τρία υποσύνολα σύμφωνα με την ετικέτα κλάσης
- Κάθε υποσύνολο περιέχει 100 δισδιάστατα δείγματα
- Για κάθε κλάση υπολογίζονται ανεξάρτητα:
  - το μέσο διάνυσμα μ
  - ο πίνακας συνδιακύμανσης Σ
- Η εκτίμηση των παραμέτρων γίνεται με εφαρμογή των εκτιμητών MLE
- Οι υπολογισμοί βασίζονται στα δεδομένα της αντίστοιχης κλάσης

1.4 Οπτικοποίηση Δεδομένων σε Δισδιάστατο Χώρο

- Τα δεδομένα απεικονίζονται στον δισδιάστατο χώρο (x_1, x_2)
- Κάθε σημείο αντιστοιχεί σε ένα δείγμα
- Διαφορετικό χρώμα χρησιμοποιείται για κάθε κλάση
- Η απεικόνιση επιτρέπει την οπτική εκτίμηση του διαχωρισμού των κλάσεων
- Παρατηρείται μερική επικάλυψη μεταξύ ορισμένων κατανομών
- Η οπτικοποίηση των δεδομένων και των εκτιμημένων κατανομών παρουσιάζεται σε τρισδιάστατο γράφημα σε επόμενη ενότητα.

1.5 Εκτιμώμενοι Μέσοι Όροι και Πίνακες Συνδιακύμανσης

- Για κάθε κλάση υπολογίστηκε το μέσο διάνυσμα $\mu = (\mu_1, \mu_2)$
- Οι μέσοι όροι καθορίζουν τη θέση της κάθε κατανομής στον δισδιάστατο χώρο
- Υπολογίστηκε ο πίνακας συνδιακύμανσης Σ διαστάσεων 2×2 για κάθε κλάση
- Οι εκτός διαγωνίου όροι του πίνακα Σ εκφράζουν τη συσχέτιση μεταξύ των χαρακτηριστικών
- Διαφορές στις τιμές της συνδιακύμανσης οδηγούν σε διαφορετικό σχήμα και προσανατολισμό των κατανομών

Κλάση	**μ_1**	**μ_2**
0	29.21	16.85
1	40.20	34.28
2	27.55	34.79

Πίνακες Συνδιακύμανσης (Σ)

- **Κλάση 0**:

  $$\Sigma = \begin{bmatrix} 46.99 & 22.91 \\ 22.91 & 48.63 \end{bmatrix}$$

- **Κλάση 1**:

  $$\Sigma = \begin{bmatrix} 9.42 & 11.49 \\ 11.49 & 20.11 \end{bmatrix}$$

- **Κλάση 2**:

  $$\Sigma = \begin{bmatrix} 13.97 & 11.77 \\ 11.77 & 25.29 \end{bmatrix}$$

1.6 Τρισδιάστατη Απεικόνιση Πυκνοτήτων Πιθανότητας (MLE)

- Για κάθε κλάση υπολογίστηκε η εκτιμημένη πυκνότητα πιθανότητας με βάση τις παραμέτρους MLE
- Οι τρεις δισδιάστατες κανονικές κατανομές απεικονίζονται ταυτόχρονα σε τρισδιάστατο γράφημα
- Οι κορυφές των επιφανειών αντιστοιχούν στους εκτιμημένους μέσους όρους των κλάσεων
- Το σχήμα και ο προσανατολισμός κάθε κατανομής καθορίζονται από τον αντίστοιχο πίνακα συνδιακύμανσης
- Στο γράφημα απεικονίζονται επίσης τα πραγματικά δείγματα, επιτρέποντας άμεση σύγκριση δεδομένων και μοντέλου

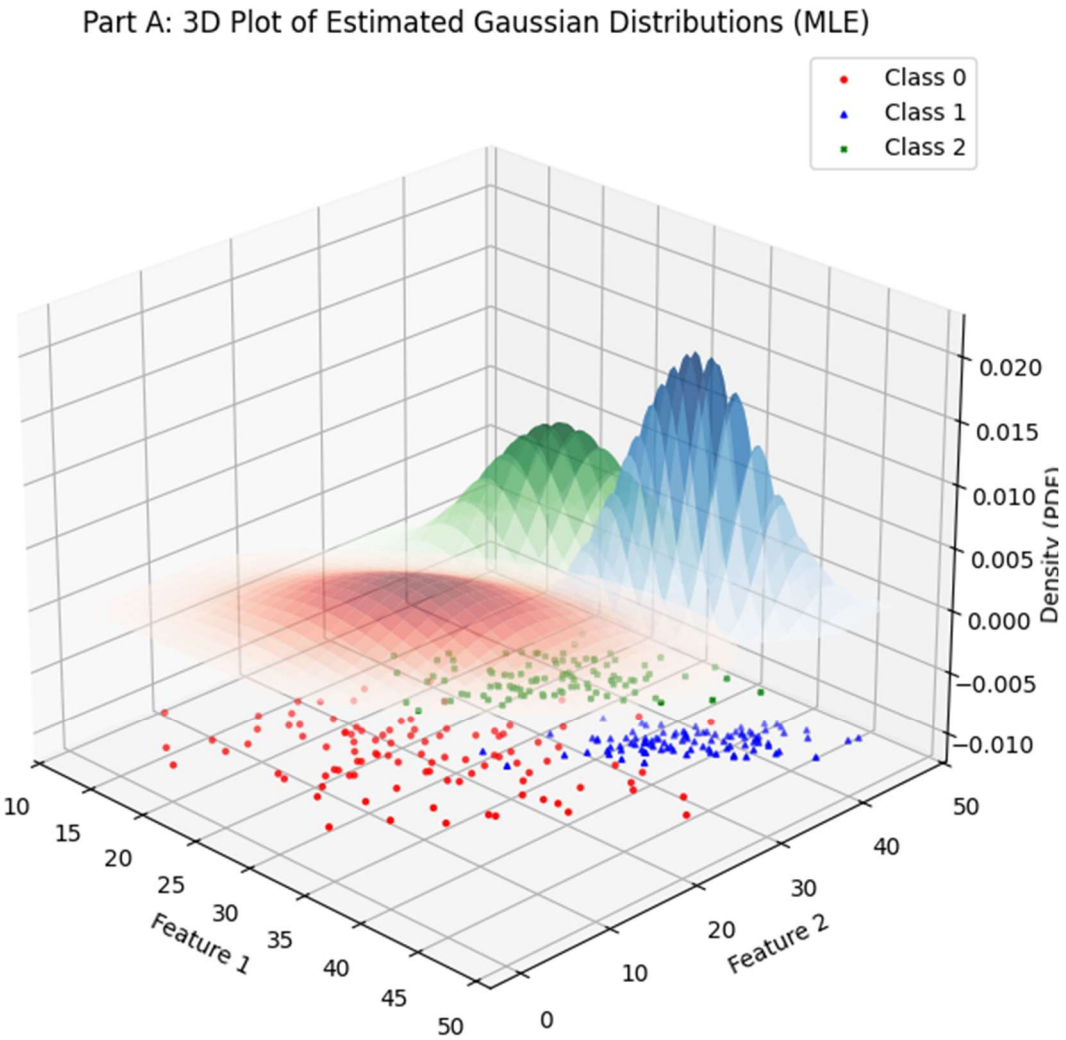

2. Μέρος Β - Εκτίμηση Πυκνότητας Πιθανότητας με Parzen Windows

2.1 Θεωρητικό Υπόβαθρο — Parzen Windows

- Η μέθοδος Parzen Windows χρησιμοποιείται για την εκτίμηση της πυκνότητας πιθανότητας από δείγματα δεδομένων
- Η εκτιμώμενη πυκνότητα δίνεται από:

$$\hat{p}(x) = \frac{1}{Nh}\sum_{i=1}^{N} K\left(\frac{x - x_i}{h}\right)$$

- Ο πυρήνας $K(\cdot)$ καθορίζει τη μορφή της συνεισφοράς κάθε δείγματος
- Το πλάτος του παραθύρου h καθορίζει πόσο ομαλή ή λεπτομερής είναι η εκτίμηση
- Μικρές τιμές του h οδηγούν σε υψηλή διακύμανση, ενώ μεγάλες τιμές σε υπερβολική εξομάλυνση
- Η σωστή επιλογή του h είναι κρίσιμη για την ποιότητα της εκτίμησης

2.2 Πυρήνες Parzen και Διαδικασία Εκτίμησης

- Για την εκτίμηση της πυκνότητας πιθανότητας χρησιμοποιήθηκαν δύο διαφορετικοί πυρήνες
- Ο υπερκύβος αποδίδει ίσο βάρος σε όλα τα δείγματα εντός του παραθύρου
- Ο Γκαουσιανός πυρήνας αποδίδει μεγαλύτερο βάρος στα δείγματα που βρίσκονται κοντά στο σημείο εκτίμησης
- Για κάθε σημείο x, η εκτίμηση υπολογίζεται ως άθροισμα των συνεισφορών όλων των δειγμάτων
- Το πλάτος του παραθύρου h είναι κοινό για όλα τα δείγματα και επηρεάζει τη μορφή της εκτίμησης

2.3 Έλεγχος Υπόθεσης Κατανομής Δεδομένων

- Τα δεδομένα θεωρούνται ότι προέρχονται από κανονική κατανομή με μέση τιμή 1 και διασπορά 4
- Για την επαλήθευση της υπόθεσης εξετάζεται η εμπειρική κατανομή των δεδομένων
- Η εμπειρική κατανομή συγκρίνεται με τη θεωρητική κανονική κατανομή
- Η σύγκριση γίνεται οπτικά, ώστε να αξιολογηθεί η καταλληλότητα της υπόθεσης
- Παρατηρείται καλή συμφωνία μεταξύ δεδομένων και θεωρητικού μοντέλου

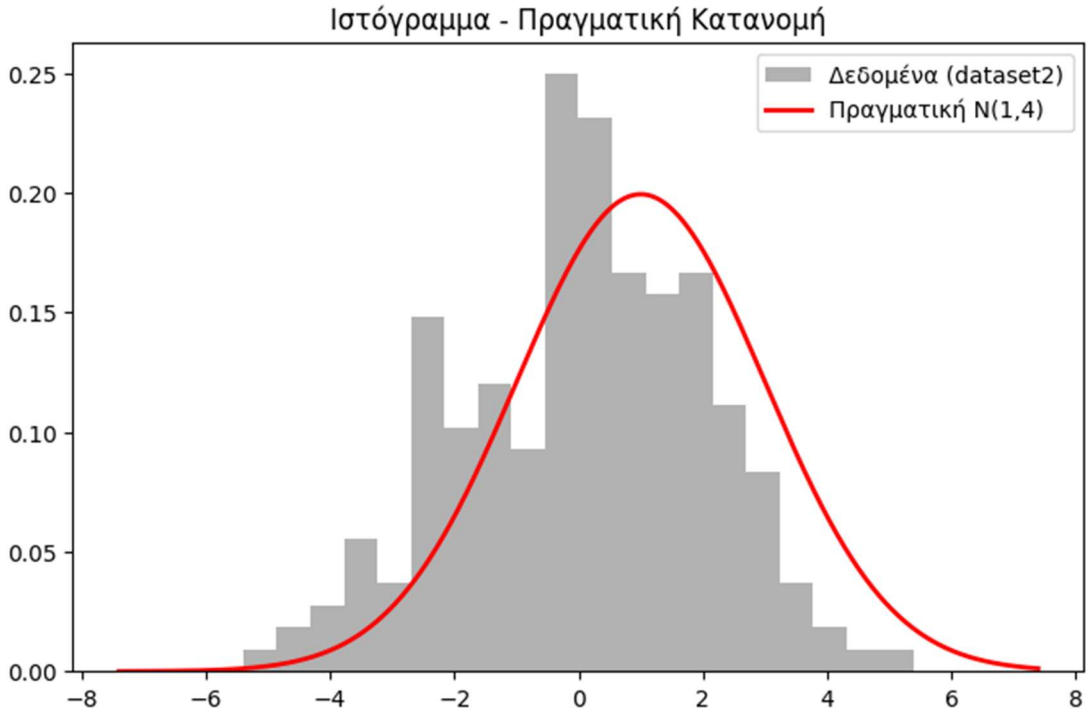

2.4 Επιλογή Πλάτους Παραθύρου (h)

- Το πλάτος του παραθύρου h επηρεάζει άμεσα την ποιότητα της εκτίμησης με Parzen Windows
- Για ένα εύρος τιμών του h υπολογίστηκε η εκτιμώμενη πυκνότητα πιθανότητας
- Για κάθε τιμή του h υπολογίστηκε το μέσο τετραγωνικό σφάλμα σε σύγκριση με τη θεωρητική κατανομή
- Η διαδικασία εφαρμόστηκε ξεχωριστά για:
    - Hypercube
    - Γκαουσιανό πυρήνα
- Η βέλτιστη τιμή του h επιλέγεται ως αυτή που ελαχιστοποιεί το MSE

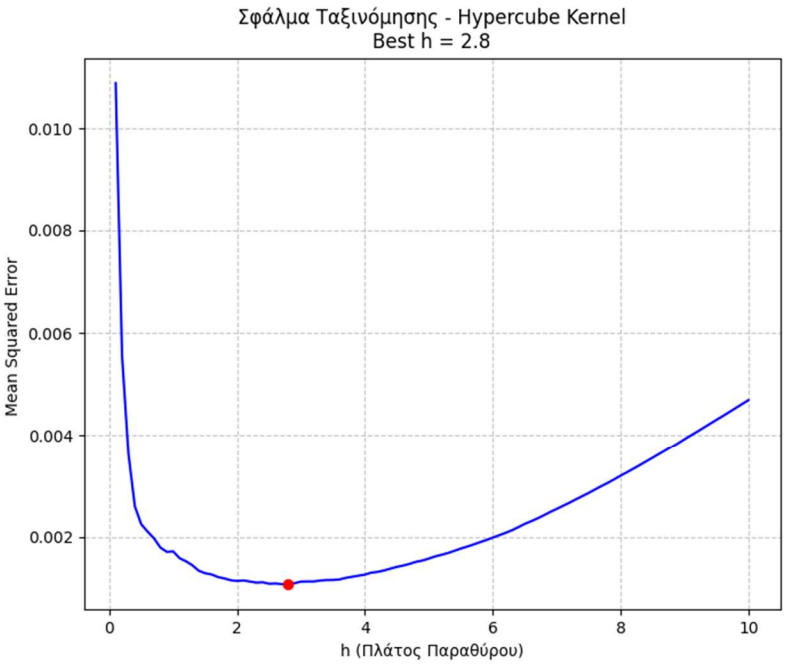

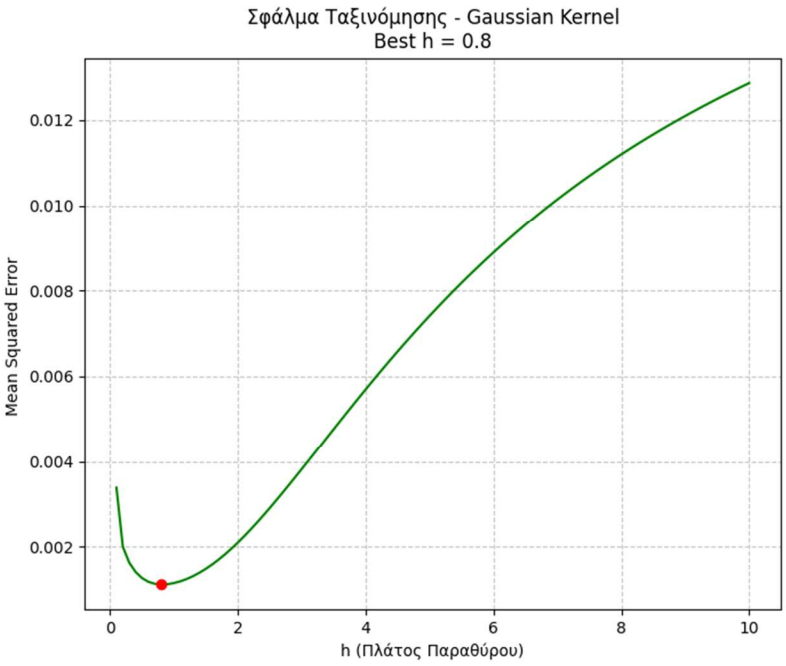

2.5 Αποτελέσματα και Σύγκριση Πυρήνων

- Για το hypercube, η βέλτιστη τιμή του πλάτους παραθύρου είναι:
    - $h = 2.8$, όπου παρατηρείται το ελάχιστο MSE
- Για τον Γκαουσιανό πυρήνα, η βέλτιστη τιμή του πλάτους παραθύρου είναι:
    - $h = 0.8$, με επίσης χαμηλό MSE
- Και στις δύο περιπτώσεις παρατηρείται σαφές ελάχιστο του σφάλματος ως προς το h
- Ο Γκαουσιανός πυρήνας επιτυγχάνει καλύτερη απόδοση για μικρότερες τιμές του h
- Η επιλογή του κατάλληλου πυρήνα και του πλάτους παραθύρου είναι καθοριστική για την ποιότητα της εκτίμησης πυκνότητας

3. Μέρος Γ - Ταξινόμηση με K-Nearest Neighbors

- Στο Μέρος Γ μελετάται το πρόβλημα της δυαδικής ταξινόμησης
- Δίνονται:
    - σύνολο εκπαίδευσης (dataset3.csv)
    - σύνολο ελέγχου (testset.csv)
- Χρησιμοποιείται ο αλγόριθμος K-Nearest Neighbors (KNN)
- Η ταξινόμηση βασίζεται στην απόσταση κάθε δείγματος από τα δεδομένα εκπαίδευσης
- Μελετάται η επίδραση της παραμέτρου **k** στην απόδοση του ταξινομητή
- Η απόδοση αξιολογείται με βάση την ακρίβεια ταξινόμησης στο σύνολο ελέγχου

3.1 Θεωρητικό Υπόβαθρο — K-Nearest Neighbors

- Ο αλγόριθμος K-Nearest Neighbors είναι μη παραμετρικός αλγόριθμος ταξινόμησης
- Η ταξινόμηση ενός δείγματος βασίζεται στους k κοντινότερους γείτονες του στο σύνολο εκπαίδευσης
- Ως μέτρο απόστασης χρησιμοποιείται η Ευκλείδεια απόσταση
- Η ετικέτα του δείγματος προκύπτει από την πλειοψηφία των ετικετών των γειτόνων
- Η πιθανότητα κάθε κλάσης υπολογίζεται ως το ποσοστό εμφάνισής της στους k γείτονες
- Η επιλογή της παραμέτρου **k** επηρεάζει άμεσα την απόδοση του ταξινομητή

3.2 Υπολογισμός Αποστάσεων και Επιλογή Γειτόνων

- Για κάθε δείγμα προς ταξινόμηση υπολογίζεται η απόστασή του από όλα τα δείγματα του συνόλου εκπαίδευσης
- Ως μέτρο απόστασης χρησιμοποιείται η Ευκλείδεια απόσταση
- Οι αποστάσεις ταξινομούνται σε αύξουσα σειρά
- Επιλέγονται οι **k κοντινότεροι γείτονες** του δείγματος
- Η διαδικασία αυτή υλοποιείται από τη συνάρτηση neighbors
- Το σύνολο των γειτόνων χρησιμοποιείται στο επόμενο βήμα για την πρόβλεψη της κλάσης

3.3 Πρόβλεψη Κλάσης και Υπολογισμός Πιθανοτήτων

- Για κάθε δείγμα του συνόλου ελέγχου επιλέγονται οι k κοντινότεροι γείτονες
- Η πρόβλεψη της κλάσης βασίζεται στις ετικέτες των επιλεγμένων γειτόνων
- Η πιθανότητα κάθε κλάσης υπολογίζεται ως:
    - αριθμός γειτόνων της κλάσης προς το συνολικό k
- Οι υπολογισμένες πιθανότητες αθροίζουν σε 1
- Η τελική κλάση αντιστοιχεί στη μέγιστη πιθανότητα
- Η διαδικασία υλοποιείται από τη συνάρτηση predict

3.4 Επιλογή Βέλτιστης Τιμής k

- Η απόδοση του ταξινομητή KNN εξαρτάται από την επιλογή της παραμέτρου k
- Εξετάστηκαν διαφορετικές τιμές του k σε προκαθορισμένο εύρος
- Για κάθε τιμή του k υπολογίστηκε η ακρίβεια ταξινόμησης στο σύνολο ελέγχου
- Η ακρίβεια χρησιμοποιείται ως κριτήριο αξιολόγησης της απόδοσης
- Η βέλτιστη τιμή του k επιλέγεται ως αυτή που μεγιστοποιεί την ακρίβεια

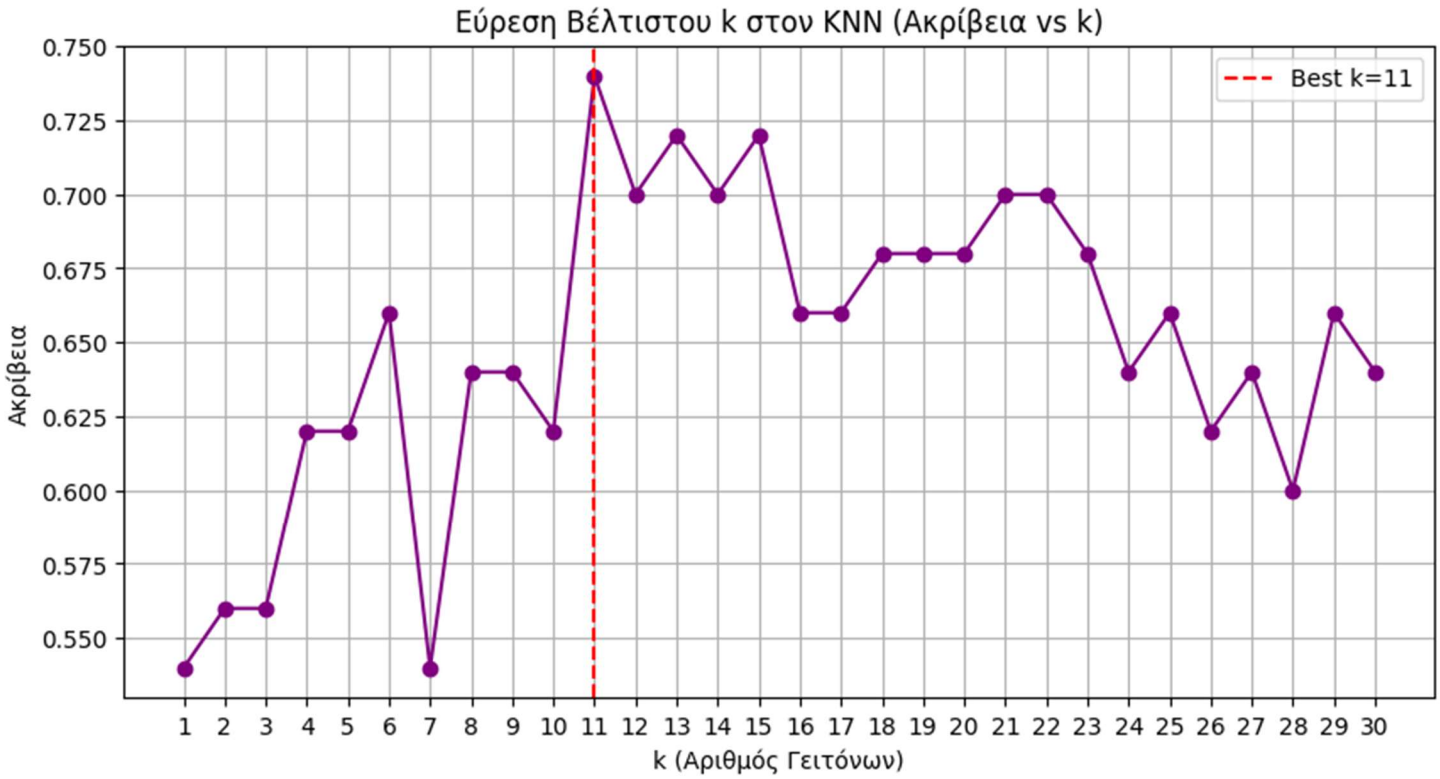

3.5 Όρια Απόφασης του KNN Ταξινομητή

- Με βάση τη βέλτιστη τιμή της παραμέτρου k, απεικονίζονται τα όρια απόφασης του ταξινομητή
- Ο χώρος των χαρακτηριστικών χωρίζεται σε περιοχές που αντιστοιχούν στις δύο κλάσεις
- Κάθε σημείο του χώρου ταξινομείται σύμφωνα με τους k κοντινότερους γείτονές του
- Τα πραγματικά δείγματα προβάλλονται πάνω στο γράφημα για σύγκριση
- Η μορφή των ορίων απόφασης εξαρτάται από την τιμή του k και την κατανομή των δεδομένων

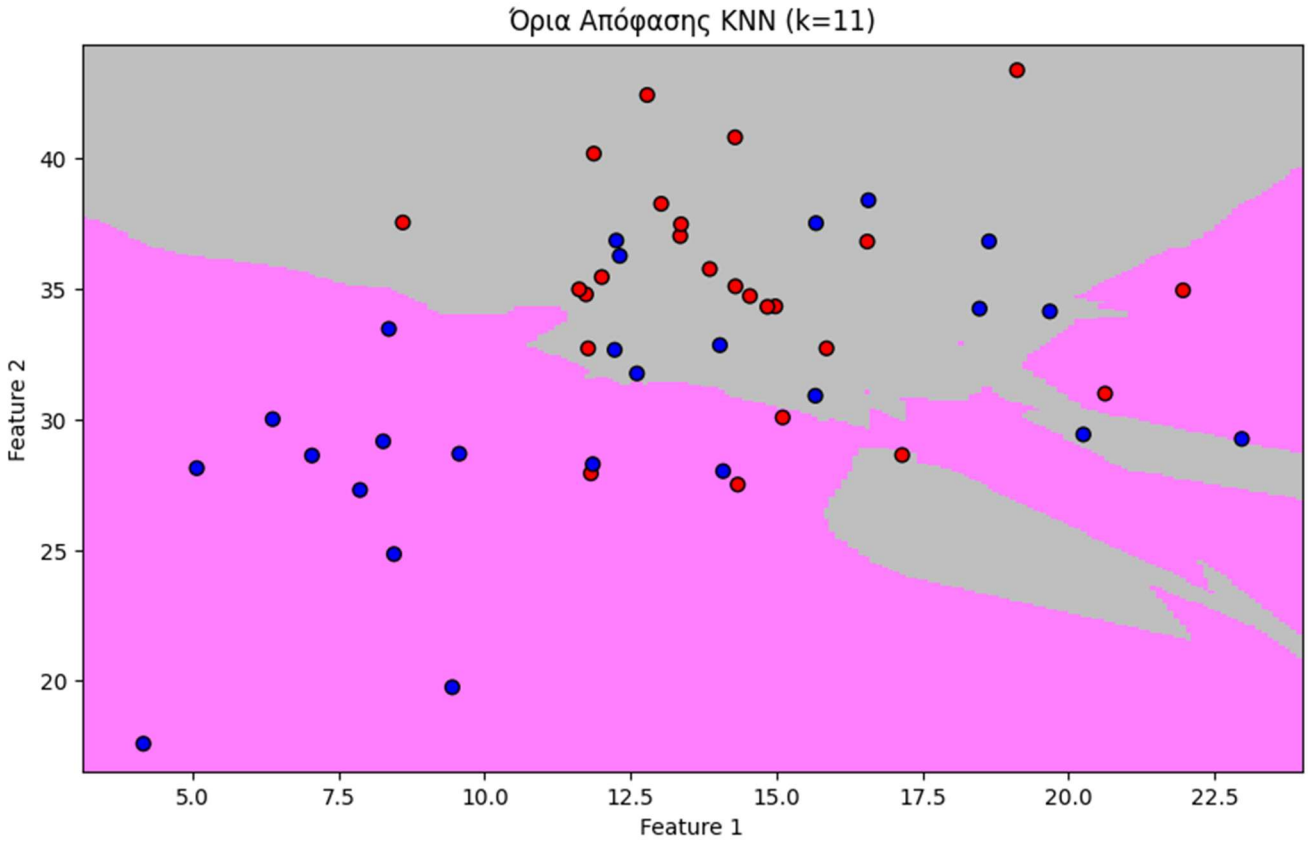

4. Μέρος Δ - Πολυκλασική Ταξινόμηση και Τελικό Μοντέλο

- Στο Μέρος Δ εξετάζεται πρόβλημα πολυκλασικής ταξινόμησης με πέντε κλάσεις
- Δίνεται σύνολο εκπαίδευσης με:
  - 8743 δείγματα
  - 224 χαρακτηριστικά ανά δείγμα
- Δίνεται επίσης σύνολο ελέγχου με 6955 δείγματα χωρίς ετικέτες
- Στόχος είναι:
  - η κατασκευή αποδοτικού ταξινομητή
  - η πρόβλεψη των ετικετών του συνόλου ελέγχου
- Το τελικό αποτέλεσμα αποθηκεύεται στο αρχείο labels22.npy

4.1 Περιγραφή Δεδομένων και Προκλήσεις Προβλήματος

- Το σύνολο εκπαίδευσης περιέχει 8743 δείγματα με 224 χαρακτηριστικά
- Το πρόβλημα αφορά πολυκλασική ταξινόμηση σε πέντε κλάσεις
- Ο μεγάλος αριθμός χαρακτηριστικών αυξάνει την πολυπλοκότητα του προβλήματος
- Υπάρχει πιθανότητα επικάλυψης μεταξύ των κλάσεων στον χώρο χαρακτηριστικών
- Η ανισορροπία μεταξύ των κλάσεων μπορεί να επηρεάσει την απόδοση των μοντέλων
- Απαιτείται κατάλληλη προεπεξεργασία και επιλογή μοντέλου για καλή γενίκευση

4.2 Προεπεξεργασία Δεδομένων

- Πριν την εκπαίδευση των μοντέλων εφαρμόστηκε προεπεξεργασία στα δεδομένα
- Χρησιμοποιήθηκε τυποποίηση των χαρακτηριστικών
- Η τυποποίηση μετατρέπει κάθε χαρακτηριστικό ώστε να έχει μηδενικό μέσο και μοναδιαία διασπορά
- Η διαδικασία αυτή είναι απαραίτητη για μοντέλα που βασίζονται σε αποστάσεις ή εσωτερικά γινόμενα
- Η προεπεξεργασία εφαρμόστηκε με τον ίδιο τρόπο τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο ελέγχου
- Η τυποποίηση βελτιώνει τη σταθερότητα και τη σύγκλιση των μοντέλων

4.3 Μείωση Διάστασης με PCA

- Το σύνολο δεδομένων περιέχει μεγάλο αριθμό χαρακτηριστικών (224), γεγονός που αυξάνει την πολυπλοκότητα του προβλήματος
- Για τον λόγο αυτό εφαρμόστηκε Ανάλυση Κύριων Συνιστωσών (PCA) για μείωση της διάστασης των δεδομένων
- Το PCA προβάλλει τα δεδομένα σε νέο χώρο χαρακτηριστικών διατηρώντας τη μέγιστη δυνατή διακύμανση
- Ο αριθμός των κύριων συνιστωσών επιλέχθηκε έτσι ώστε να διατηρείται το 95% της συνολικής διακύμανσης
- Η εφαρμογή του PCA συμβάλλει στη μείωση του θορύβου και στη βελτίωση της γενίκευσης των μοντέλων
- Το PCA εφαρμόστηκε ενσωματωμένο στα pipelines των μοντέλων, μετά την κατάλληλη προεπεξεργασία

4.4 Αρχικά Μοντέλα Ταξινόμησης

- Αρχικά δοκιμάστηκαν διάφορα μοντέλα πολυκλασικής ταξινόμησης
- Τα μοντέλα εκπαιδεύτηκαν και αξιολογήθηκαν με κοινό πρωτόκολλο
- Συγκεκριμένα εξετάστηκαν:
    - Logistic Regression
    - Support Vector Machine
    - Random Forest
    - k-Nearest Neighbors
    - Gradient Boosting
- Η απόδοση κάθε μοντέλου αξιολογήθηκε με βάση την ακρίβεια ταξινόμησης
- Για πληρέστερη αξιολόγηση παρουσιάζονται οι πίνακες σύγχυσης (confusion matrices)

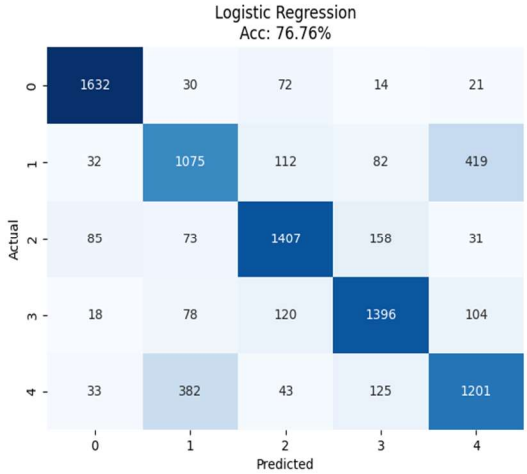

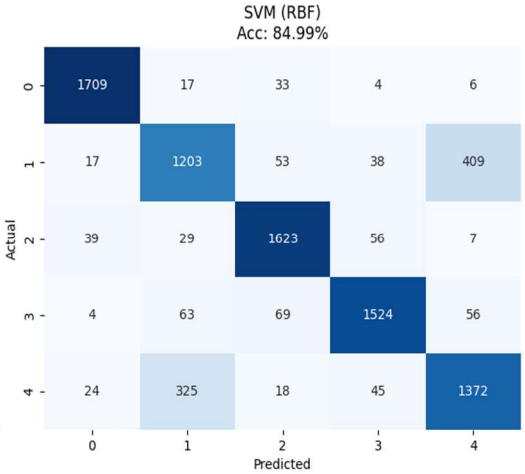

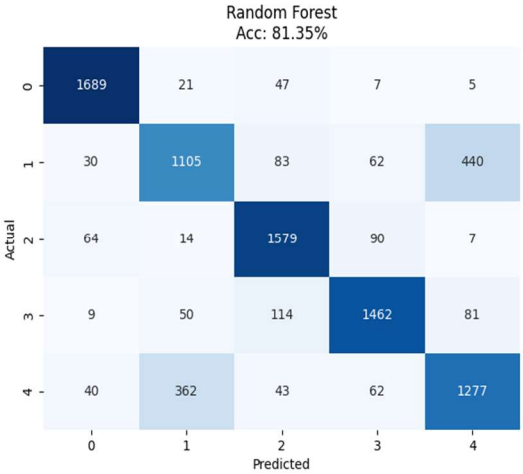

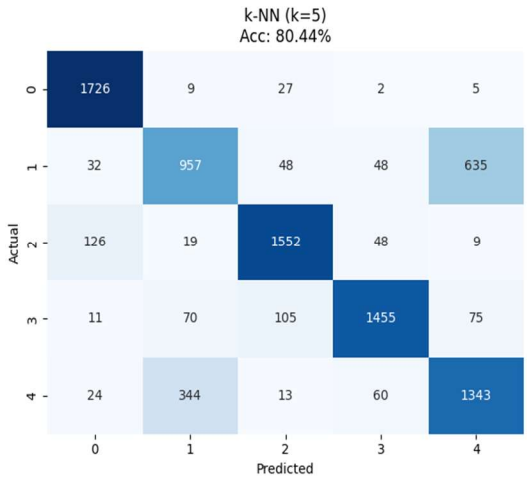

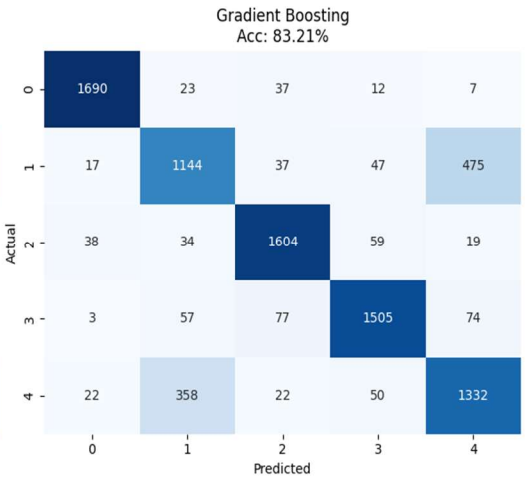

4.5 Παρατηρήσεις από τα Αποτελέσματα

- Τα μοντέλα επιτυγχάνουν ικανοποιητική αλλά όχι βέλτιστη ακρίβεια
- Από τους πίνακες σύγχυσης παρατηρείται σύγχυση μεταξύ συγκεκριμένων κλάσεων
- Ορισμένες κλάσεις παρουσιάζουν παρόμοια κατανομή στον χώρο χαρακτηριστικών
- Μεταξύ των δοκιμασμένων μοντέλων, τα SVM εμφανίζουν τη σταθερότερη και υψηλότερη απόδοση
- Ωστόσο, η απλή πολυκλασική εφαρμογή τους δεν επιλύει πλήρως το πρόβλημα σύγχυσης
- Τα αποτελέσματα υποδεικνύουν ότι απαιτείται πιο στοχευμένη στρατηγική ταξινόμησης
- Για τον λόγο αυτό εξετάστηκε μια ιεραρχική προσέγγιση, βασισμένη σε SVM ταξινομητές

4.6 Ιεραρχική Προσέγγιση Ταξινόμησης

- Από την ανάλυση των πινάκων σύγχυσης των μοντέλων παρατηρείται ότι οι κλάσεις 1,3,4 προβλέπονται με υψηλή ακρίβεια
- Αντίθετα, οι κλάσεις 2 και 5 εμφανίζουν έντονη σύγχυση μεταξύ τους
- Η σύγχυση αυτή επηρεάζει σημαντικά τη συνολική απόδοση του πολυκλασικού ταξινομητή
- Με βάση αυτή την παρατήρηση, οι κλάσεις χωρίστηκαν σε δύο ομάδες:
    - **Group A**: κλάσεις 1,3,4 ταξινομούνται με υψηλή ακρίβεια
    - **Group B**: κλάσεις 2 και 5, οι οποίες παρουσιάζουν σύγχυση μεταξύ τους
- Ο διαχωρισμός αυτός επιτρέπει την εφαρμογή εξειδικευμένων ταξινομητών για κάθε ομάδα
- Η ιεραρχική προσέγγιση στοχεύει στη βελτίωση της απόδοσης, εστιάζοντας στο πιο δύσκολο υποπρόβλημα

4.7 Μοντέλο για το Group A

- Το Group A περιλαμβάνει τις κλάσεις που προβλέπονται με υψηλή ακρίβεια στα μοντέλα
- Για το Group A χρησιμοποιήθηκε ταξινομητής Support Vector Machine
- Το pipeline του μοντέλου αποτελείται από:
    - τυποποίηση χαρακτηριστικών (StandardScaler)
    - μείωση διάστασης με PCA (95% διατηρούμενη διακύμανση)
    - SVM με RBF πυρήνα
- Για τη βελτιστοποίηση των υπερπαραμέτρων εφαρμόστηκε Grid Search
- Η βέλτιστη παράμετρος που προέκυψε είναι:
    - $C = 5$
- Το μοντέλο επιτυγχάνει ακρίβεια 95.46%, υποδεικνύοντας πολύ καλή απόδοση στο συγκεκριμένο υποπρόβλημα

4.8 Μοντέλο για το Group B

- Το Group B περιλαμβάνει τις κλάσεις 2 και 5, οι οποίες παρουσιάζουν έντονη σύγχυση μεταξύ τους
- Το υποπρόβλημα αυτό είναι πιο απαιτητικό και απαιτεί διαφορετική προεπεξεργασία
- Μετά από πειραματισμό διαπιστώθηκε ότι η κανονικοποίηση (Normalizer) είναι πιο αποδοτική από την τυποποίηση
- Για τον λόγο αυτό, το pipeline του μοντέλου αποτελείται από:
    - κανονικοποίηση χαρακτηριστικών (Normalizer)
    - μείωση διάστασης με PCA (95% διατηρούμενη διακύμανση)
    - SVM ταξινομητή
- Για τη βελτιστοποίηση των υπερπαραμέτρων εφαρμόστηκε Grid Search
- Η βέλτιστη παράμετρος που προέκυψε είναι:
    - $C = 5$
- Το μοντέλο επιτυγχάνει ακρίβεια 78.28%, που δείχνει τη δυσκολία του διαχωρισμού των κλάσεων 2 και 5

4.9 Τελικό Ιεραρχικό Μοντέλο και Αξιολόγηση

- Το τελικό σύστημα ταξινόμησης βασίζεται σε ιεραρχική δομή τριών σταδίων
- Αρχικά εφαρμόζεται ταξινομητής που διαχωρίζει τα δείγματα σε:
    - Group A
    - Group B
- Στη συνέχεια, κάθε δείγμα ταξινομείται από τον αντίστοιχο εξειδικευμένο ταξινομητή της ομάδας του
- Η αξιολόγηση του συστήματος πραγματοποιήθηκε με Stratified Cross-Validation
- Η ιεραρχική προσέγγιση επιτρέπει καλύτερο χειρισμό των δύσκολων κλάσεων
- Η τελική ακρίβεια που προέκυψε είναι:
    - **86.03% (CV Score)**

4.10 Παραγωγή Τελικών Προβλέψεων

- Μετά την ολοκλήρωση της αξιολόγησης, το τελικό ιεραρχικό μοντέλο εκπαιδεύτηκε στο πλήρες σύνολο εκπαίδευσης
- Το εκπαιδευμένο μοντέλο εφαρμόστηκε στο σύνολο ελέγχου που δεν διαθέτει ετικέτες
- Για κάθε δείγμα του συνόλου ελέγχου προβλέφθηκε η αντίστοιχη κλάση
- Οι τελικές προβλέψεις αποθηκεύτηκαν σε αρχείο labels22.npy
- Το αρχείο περιέχει 6955 ετικέτες, μία για κάθε δείγμα του συνόλου ελέγχου

4.11 Συμπεράσματα Μέρους Δ

Στο μέρος Δ αντιμετωπίστηκε ένα απαιτητικό πρόβλημα πολυκλασικής ταξινόμησης με μεγάλο αριθμό χαρακτηριστικών. Τα αρχικά πειράματα με βασικά μοντέλα ανέδειξαν δυσκολίες στον διαχωρισμό ορισμένων κλάσεων, γεγονός που επηρέαζε τη συνολική απόδοση του συστήματος. Η ανάλυση των πινάκων σύγχυσης έδειξε ότι οι κλάσεις 2 και 5 παρουσιάζουν έντονη σύγχυση μεταξύ τους, ενώ οι υπόλοιπες κλάσεις προβλέπονται με μεγαλύτερη αξιοπιστία.

Με βάση τις παρατηρήσεις αυτές, υιοθετήθηκε ιεραρχική προσέγγιση ταξινόμησης, η οποία επέτρεψε τη διάσπαση του προβλήματος σε απλούστερα υποπροβλήματα. Η χρήση εξειδικευμένων SVM ταξινομητών, σε συνδυασμό με κατάλληλη προεπεξεργασία και μείωση διάστασης μέσω PCA, οδήγησε σε αισθητή βελτίωση της απόδοσης. Το τελικό ιεραρχικό μοντέλο πέτυχε ακρίβεια 86.03%, επιβεβαιώνοντας ότι η στοχευμένη αντιμετώπιση των δύσκολων κλάσεων μπορεί να βελτιώσει σημαντικά τη γενική συμπεριφορά του συστήματος. Η προτεινόμενη μεθοδολογία είναι γενική και μπορεί να εφαρμοστεί και σε άλλα προβλήματα πολυκλασικής ταξινόμησης με παρόμοια χαρακτηριστικά.